

SMC-menetelmät

Laskennallinen tilastotiede - Harjoitustyö

Lasse Rintakumpu

09 May, 2021

Sisällys

1 Johdanto	2
1.1 Suodinongelma	2
1.2 Historiaa	3
2 Bayesilainen suodin	4
3 Tärkeytysotanta	5
4 SIR-algoritmi	6
4.1 Parametrien valinta	7
4.1.1 Otoskoon N valinta	7
4.1.2 Uudelleenottamisen menetelmän valinta	8
4.1.3 Ehdotusjakauman valinta	8
4.2 Konvergenssituloksia	9
4.3 Marginaalijakauma	10
4.4 Aikakompleksisuus	10
5 Paikannusesimerkki	10
5.1 Koeasetelma	10
5.2 Datan kuvaus	13
5.3 Ongelman kuvaus	14
5.4 Algoritmi	14
5.5 Tulokset	14
6 Lopuksi	15
7 Lähteet	15

1 Johdanto

SMC-menetelmät (sequential Monte Carlo -menetelmät) ovat joukko 90-luvulta eteenpäin kehitettyjä Monte Carlo -algoritmeja, joiden avulla voidaan ratkaista ns. suodinongelma, kun ongelma on epälineaarinen ja/tai ongelmaan liittyvä kohina ei noudata normaalijakaumaa. Tämän tutkielman tavoitteena on esittää pääpiirteitäin SMC-menetelmien teoria sekä joitakin menetelmäperheeseen kuuluvia algoritmeja. Tutkielman esitykset seuraavat erityisesti Simo Särkän kirjaa *Bayesian Filtering and Smoothing* (2013), Fredrik Gustafssonin artikkelia “Particle Filter Theory and Practice with Positioning Applications” (2010) sekä Cappé & al artikkeliin “An overview of existing methods and recent advances in sequential Monte Carlo” (2007). SMC-menetelmille on lukuisia sovellutuksia esimerkiksi Bayesilaisessa tilastotieteessä, fysiikassa ja robotiikassa. Tutkielman lopussa tarkastellaan menetelmien käyttöä paikanlussovelluksessa.

1.1 Suodinongelma

Stokastisten prosessien teoriassa suodinongelmaksi kutsutaan tilannetta, jossa halutaan muodostaa paras mahdollinen estimaatti jonkin järjestelmän tilan arvoille, kun ainoastaan osa tiloista voidaan havaita ja/tai havaintoihin liittyy kohinaa. Tavoitteena on siis laskea jonkin prosessin posteriorijakauma kyseisten havaintojen perusteella. Tässä tutkielmassa keskitytään erityisesti epälineaarisen ns. Markovin piilomallin posteriorijakauman Bayesilaiseen ratkaisuun. Ongelmaa havainnollistaa kaavio (1).

$$\begin{array}{ccccccc} X_1 & \longrightarrow & X_2 & \longrightarrow & X_3 & \longrightarrow & \dots \\ \downarrow & & \downarrow & & \downarrow & & \\ Y_1 & & Y_2 & & Y_3 & & \dots \end{array} \quad \begin{array}{l} \text{piilossa olevat tilat} \\ \text{havainnot} \end{array} \quad (1)$$

Ongelmassa tiedämme, miten havaitut muuttujat Y_k kytkeytyvät “piilossa oleviin” muuttuijiin X_k sekä osaamme sanoa jotain tilamuuttujien todennäköisyysistä. Oletamme, että piilossa oleville tiloille X_k pätee Markov-ominaisuus. Toisin sanoen kutakin hetkeä seuraavaa tila x_{k+1} riippuu menneistä tiloista $x_{1:k}$ ainoastaan tilan x_k välityksellä. Oletamme myös, että havaittu tila y_k riippuu tiloista X_k ainoastaan jonkin x_k :n funktion kautta. Kun aika-avaruus on diskreetti ja merkitsemme ajanhettellä $k = 1, \dots, t$ piilossa olevan prosessin tilaa x_k ja havaittua prosessia y_k , meillä on siis olemassa mallit

$$x_{k+1} = f(x_k, \nu_k) \quad (2)$$

$$y_k = h(x_k) + e_k. \quad (3)$$

Lisäksi tiedetään prosessin alkuperäisen jakauman $x_1 \sim p_{x_1}$, tähän liittyvän kohinprosessin jakauman $\nu_k \sim p_{\nu_k}$ sekä malliin y_k liittyvä kohina $e_k \sim p_{e_k}$. Koska SMC-algoritmit pyrkivät ratkaisemaan juurikin epälineaarisen, ei-Gaussisen suodinongelman, voivat funktiot $f(\cdot)$ ja $h(\cdot)$ olla epälineaarisia eikä kohinan tarvitse olla normaalijakautunutta.

Mallit voidaan esittää myös yleisemmässä jakaumamuodossa

$$x_{k+1} \sim p(x_{k+1}|x_k), \quad (4)$$

$$y_k \sim p(y_k|x_k). \quad (5)$$

Tutkielman teoriaosassa käytetään ensisijaisesti yhtälöiden (4) ja (5) muotoilua. Empiirisessä osassa palataan yhtälöiden (2) ja (3) muotoiluun.

Yleisesti suodinongelman estimaatit saadaan posteriorijakaumasta $p(x_k|y_1, y_2, \dots, y_k)$. Posteriorijakauma voidaan kuitenkin laskea suljetussa muodissa vain, jos kyseessä on lineaarinen, Gaussinen malli. Yllä määritetyjen mallien avulla SMC-menetelmät muodostavat sekventiaalisesti tilojen X_k Monte Carlo -estimaatit minä hyvänsä ajan hetkellä k , kun ainoastaan prosessi Y_1, \dots, Y_k tunetaan. Kuten mainittua, ei SMC-perheen algoritmeja käytettäessä mallin $y_k = h(x_k) + e_k$ tarvitse olla lineaarinen eikä kohinaprosessien noudataa normaalijakaumaa.

SMC-menetelmässä stokastisen prosessin posteriorijakauman esittämiseen käytettyjä otoksia kutsutaan myös partikkeleiksi ja menetelmiä hiukassuotimiksi. Erityisesti myöhemmin esitettävä SIR-algoritmia kutsutaan usein hiukassuotimeksi. Tässä tutkielmana pyritään korostamaan suotimien yhteyttä Monte Carlo -algoritmeihin ja käytetään siksi yleisempää termiä SMC-menetelmät.

Suodinongelmaa lähellä on myös ns. tasoitusongelma (smoothing problem), jossa ollaan kiinnostuneita prosessin x_k posteriorijakaumasta $p(x_k|y_k)$ jokaisena ajanhetkenä $1, \dots, k$ ei ainostaan haluttuna ajanhetkenä k . Tämä tutkielma keskittyy yksin suodinongelman ratkaisemiseen, mutta huomioitavaa on, että SMC-algoritmit näyttävät ratkaisevan tasoitusongelman ilmaiseksi. Tähän liittyy kuitenkin joidenkin mallien kohdalla mahdollista epätarkkuutta, joten tarvittaessa tasoitusongelma pitää ratkaista erikseen.

1.2 Historiaa

Tämä alaluku esittää pääpiirteitäan suodinongelmalle esitettyjen ratkaisujen historian. Lineaarisen suodinongelman osalta alaluku noudattaa Crisanin artikkelia “The stochastic filtering problem: a brief historical account” (2014) sekä Grewalin ja Andrewsin artikkelia “Applications of Kalman Filtering in Aerospace 1960 to the Present” (2010), SMC-menetelmien osaltaan Cappé & al artikkelia “An overview of existing methods and recent advances in sequential Monte Carlo” (2007). SMC-menetelmässä sivutetaan siis viimeisen viidentoista vuoden kehitys. Tämä on linjassa tutkielman varsinaisen teoriaosuuden kanssa.

Suodinongelma nousi esille erityisesti insinöörityteteiden sekä sotateollisuuden käytännön ongelmista 2. maailmansodan aikana, vaikkakin suodinongelman diskreetin ajan ratkaisut juontavat jo Andrei N. Kolmogorovin 30-luvun artikkeleihin. Jatkuvan ajan tilanteessa ensimmäinen optimaalisen, kohinan sullivan suotiman esitti matemaatikko, kybernetiikan kehittäjä Norbert Wiener. Wiener-suotimena tunnetaan ratkaisuaan varten Wiener muotoili myös seuraavat kolme ominaisuutta, jotka prosessin X estimaatin \hat{X}_t pitää toteuttaa.

1. *Kausaliteetti*: X_t tulee estimoida käyttää arvoja Y_s , missä $s \leq t$.
2. *Optimaalisuus*: X_t :n estimaatin \hat{X}_t tulee minimoida keskineliövirhe $\mathbb{E}[(X - \hat{X}_t)^2]$.
3. *On-line -estimointi*: Estimaatin \hat{X}_t tulee olla saatavissa minä hyvänsä ajanhetkenä t .

Wiener sovelsi ratkaisussaan stationaarisien prosessien spektriteoriaa ja tulokset julkaistiin salaisina Yhdysvaltojen asevoimien tutkimuksesta vastanneen National Defense Research Committeeen (NDRC) raportissa vuonna 1942. Tutkimus tunnettiin sodan aikana lempinimellä ”Keltainen vaara” sekä painopaperinsa värin että vaikeaselkoiisuutensa vuoksi. Myöhemmin Wiener esitti tulokset julkisesti kirjassaan *Extrapolation, Interpolation and Smoothing of Stationary Time Series*. Wienerin alkuperäiset kolme perusperiaatetta pätevät edelleen kaikille suodinongelman ratkaisuille, myös SMC-menetelmille.

Kenties tärkein ja varmasti tunnetuin lineaariseen suodinongelman ratkaisu on Kalman-suodin. Suotimen kehittivät R.E. Kalman ja R.S. Bucy 1950- ja 60-lukujen taitteessa Yhdysvaltain kylmän sodan kilpavarustelutarpeisiin perustetussa Research Institute for Advanced Studies -tutkimuslaitoksessa (RIAS). Kalman-suodin on suodinongelman diskreetin ajan ratkaisu, kun taas Kalman-Bucy-suodin on jatkuvan ajan ratkaisu. Kohinan ollessa normaalijakautunutta on Kalman-suodin Wiener-suotimen tavoin lineaarisen suodinongelman optimaalinen ratkaisu. Wiener-suotimella ja Kalman-suotimella on kuitenkin erilaiset oletukset, minkä vuoksi erityisesti säätö- ja paikannusovelluksissa Kalman-suotimen käyttö on luontevampaa. Suotimien oletuksia ja oletusten välisiä eroja ei käsitellä tässä tutkielmana, kuten ei käsitellä myöskaän Kalman-suotimen formaalia yhteyttä SMC-menetelmiin.

Kalman-suodinta voidaan soveltaa myös epälineaariseen ongelmaan, kunhan funktiot $f(\cdot)$ ja $h(\cdot)$ ovat derivoituvia ja niihin liittyvä kohina oletetaan normaalijakautuneeksi. Tätä rataisiaa kutsutaan laajennetuksi Kalman-suotimeksi (extended Kalman filter, EKF). Suodin kehitettiin erityisesti NASA:n Apollo-ohjelman tarpeisiin, vaikkakin itse avaruusalusten laitteistot hyödynsivät lentoatojen laskennassa Kalman-suotimen perusversiota. Laajennetun Kalman-suotimen toimintaperiaate perustuu epälineaaristen funktioiden lineaarisointiin Taylorin kehitelmän avulla kulloisenkin estimaatin ympärillä. Laajennettu Kalman-suodin on erityisesti paikannusovellusten *de facto* -suodinstandardi, mutta suodin ei kuitenkaan ole epälineaarisen ongelman optimaalinen estimaattori.

Kalman-suotimesta on lisäksi olemassa lukuisia muita epälineaarisiin ongelmiin soveltuivia laajennuksia,

muun muassa paikkaratkaisun Kalman-suodin (position Kalman filter, PKF), hajustamaton Kalman-suodin (unscented Kalman filter, UKF) ja tilastollisesti linearisoitu Kalman-suodin (statistically linearized Kalman filter, SLF). Kuitenkin jos prosessin X mallia ei tunneta tarkasti tai kohinaa ei voida olettaa normaalijakautuneeksi, ovat sekventiaaliset Monte Carlo -menetelmät Kalman-suotimen johdannaisia parempia ratkaisuja. Vaikka tila-avaruuden dimensioiden kasvaessa kasvaa myös SMC-menetelmien vaatima laskentateho, ovat nämä menetelmät aina sitä parempia mitä epälineaarisempia mallit ovat ja mitä kauempana normaalijakumasta kohina on. Viimeisten vuosikymmenten aikana myös laskennan teho on kasvanut merkittävästi samalla kun laskennan hinta on vastaavasti romahtanut. Nämä seikat puoltavat Monte Carlo -menetelmien käyttöä entistä useammissa ongelmissa.

Jotakin suodinongelman rekursiivisia Monte Carlo -ratkaisuja löytyy 50-70-luvulta, erityisesti säätöteoriaan piiristä. Olennainen oivallus oli tärkeytysotannan käyttö halutun jakaumaestimaatin laskennassa. Tärkeytysotantaan voidaan turvautua, kun emme pysty suoraan tekemään havaintoja jostakin jakaumasta p ja teemme sen sijaan havaintoja jakaumasta q , joita painotamme niin, että tuloksena saadaan jakauman p harhaton estimaatti. Algoritmi on kuvattu tarkemmin tutkielman luvussa 3.

Tärkeytysantaa käyttävä suodinongelman ratkaiseva SIS-algoritmi (sequential importance sampling) ei kuitenkaan vielä 70-luvulla löytänyt suurta käytännön suosiota. Osin tämä johtui puutteellisesta laskentatehosta, mutta algoritmi kärsi myös otosten ehtymisenä (sample impoverishment) tunnetusta ongelmasta. Monissa ongelmissa SIS-algoritmia käytettäessä suuri osa painoista päätyy vain tietyille partikkeleille, jolloin vastaavasti suuri osa partikkeleista ei enää estimoi haluttua jakaumaa. Tähän ongelmaan palataan myöhemmin tukielmanmassa.

Merkittävä ratkaisun eehtymisongelmaan esittivät Gordon, Salmond ja Smith artikkelissaan “Novel approach to nonlinear/non-Gaussian Bayesian state estimation” (1993). Artikkelin ratkaisu kulki nimellä “bootstrap filter”, saapasremmisuodin. Saapasremmisuodin välitti ehtymisen uudellenotannalla, jossa matalapainoiset partikkelit korvattiin otoksilla korkeapainoisemmista partikkeleista. Ratkaisussa painot eivät myöskään riipu partikkelien aiemmista poluista vaan ainoastaan havaintojen uskottavuusfunktiossa.

Vastaavaa ratkaisua käytetään myös tämän tutkielman uudemmassa SIR-algoritmissa (sampling importance resampling), jossa uudelleenotannassa käytetään tärkeytysantaa. Termiä hiukkassuodin käytti ensimmäisen kerran Del Moral artikkelissa “Nonlinear Filtering: Interacting Particle Resolution” (1996). SMC-menetelmät termiä Liu ja Chen artikkelissa “Sequential Monte Carlo Methods for Dynamic Systems” (1998).

2 Bayesilainen suodin

Suodinongelmassa ollaan kiinnostuttu tilavektorin posteriorijakauman $p(x_k|y_{1:k})$ estimoinnista. Tässä luvussa käydään läpi epälineaarisen tilanteen yleinen rekursiivinen, Bayesilainen posteriorijakauman laskenta. Tällaista suodinongelman ratkaisua kutsutaan myös Bayesilaiseksi suotimeksi. Koska epälineaarisessa, ei-normaalijakautuneessa tilanteessa rekursiota ei voida laskea analyttisesti, pitää estimoinnissa käyttää numerisia menetelmiä. SMC-menetelmissä tämä tarkoittaa jakauman sekventiaalista Monte Carlo -approksimointia, jonka toteutus esitetään luvun 4 algoritmissa. Esitys noudattaa Gustafssonin artikkelia “Particle Filter Theory and Practice with Positioning Applications” (2010).

Bayesilainen ratkaisu tilavektorin posteriorijakauman estimaatiolle $\hat{p}(x_k|y_{1:k})$ saadaan seuraavalla rekursiolla (käydään läpi jokaiselle ajanhetkelle $k = 1, \dots, t$). Lasketaan ensin

$$p(x_k|y_{1:k}) = \frac{p(y_k|x_k)p(x_k|y_{1:k-1})}{p(y_k|y_{1:k-1})}, \quad (6)$$

joka saadaan suoraan Bayesin kaavasta $P(A|B) = P(B|A)P(A)/P(B)$. Normalisointivakio lasketaan integraalina

$$p(y_k|y_{1:k-1}) = \int_{\mathbb{R}^{n_x}} p(y_k|x_k)p(x_k|y_{1:k-1}) dx_k, \quad (7)$$

joka saadaan kokonaistodennäköisyyksaavasta $P(A) = \mathbb{E}[P(A|X)] = \int_{-\infty}^{\infty} P(A|X=x) f_X(x) dx$. Merkintä R^{n_x} vastaa tässä piilossa olevien muuttujien dimensiota n .

Lopuksi lasketaan päivitysaskel ajalle, joka saadaan edelleen kokonaistodennäköisyydellä

$$p(x_{k+1}|y_{1:k}) = \int_{\mathbb{R}^{n_x}} p(x_{k+1}|x_k) p(x_k|y_{1:k}) dx_k. \quad (8)$$

Rekursion avulla voimme laskea jakauman $p(x_k|y_{1:k})$ käymällä rekursio läpi k kertaa.

3 Tärkeytysotanta

Tässä luvussa kuvataan lyhyesti SMC-menetelmissä käytettävä tärkeytysotanta (importance sampling), jonka tarkoituksena on estimoida harhattomasti jakaumaa $p(x|y_{1:k})$, josta emme voi suoraan tehdä otoksia, mutta jota voimme approksimoida toisella jakaumalla q . Esitys perustuu Särkän kirjaan *Bayesian Filtering and Smoothing* (2013).

Oletetaan, että tunnemme priorijakauman $p(x)$ sekä meillä on olemassa havaintomalli $p(y_{1:k}|x)$ sekä valittu ehdotusjakauma $q(x|y_{1:k})$, josta voimme tehdä otoksia ja jonka kantaja on suurempi tai yhtä suuri kuin jakauman $p(x|y_{1:k})$ ja joka saa nollasta poikkeavia arvoja kaikkialla missä $p(x|y_{1:k})$ saa nollasta poikkeavia arvoja. Kirjoitetaan halutun posteriorijakauman odotusarvo integraalina

$$\int g(x)p(x|y_{1:k})dx = \int g(x)p(x|y_{1:k})dx = \int g(x)\frac{p(x|y_{1:k})}{q(x|y_{1:k})}q(x|y_{1:k})dx. \quad (9)$$

jolle voidaan muodostaa Monte Carlo -approksimaatio tekemällä N otosta jakaumasta $x^i \sim q(x|y_{1:k})$ ja muodostamalla odotusarvo

$$\mathbb{E}[g(x)|y_{1:k}] \simeq \frac{1}{N} \sum_{i=1}^N \frac{p(x^i|y_{1:k})}{q(x^i|y_{1:k})} g(x^i) = \sum_{i=1}^N w^i g(x^i). \quad (10)$$

Missä $g(x)$ on jokin estimoinnissa hyödyllinen, mielivaltainen funktio. Tärkeytysotantaa kuvaa nyt algoritmi (1). Kun posteriorijakauman estimaatti muodostetaan kyseisellä algoritmilla voidaan tulos kirjoittaa

$$\hat{p}(x|y_{1:k}) = \sum_{i=1}^N w_{k|k}^i \delta(x - x^i) \quad (11)$$

missä $\delta(x)$ on Diracin deltafunktio.

Algorithm 1: Tärkeytysotanta

```

begin
  for  $i = 1, 2, \dots, N$  do
    begin
      | Otetaan  $N$  otosta ehdotusjakaumasta  $x^i \sim q(x|y_{1:k})$ .
    begin
      | Lasketaan normalisoimattomat painot  $w_*^i = p(y_{1:k}|x^i)p(x^i)/q(x^i|y_{1:k})$ .
      | ja normalisoidut painot  $w^i = w_*^i / \sum_{j=1}^N w_*^j$ .
    begin
      | Estimoidaan  $p$  laskemalla tiheydelle approksimaatio  $\mathbb{E}[g(x)|y_{1:k}] \simeq \sum_{i=1}^N w^i g(x^i)$ .
  
```

4 SIR-algoritmi

Tässä luvussa esitetään SMC-menetelmiin kuuluva SIR-algoritmi Bayesilaisen, epälineaarisen suodinongelman ratkaisemiseksi. Algoritmi on numeerinen toteutus luvussa 2. kuvatusta Bayesilaisesta suotimesta. Esitetyt algoritmi perustuu Fredrik Gustafssonin artikkeliin “Particle Filter Theory and Practice with Positioning Applications” (2010).

Algoritmi alustetaan jakaumasta $x_1^i \sim p_{x_0}$ generoiduilla N -kappaleella partikkeleita. Jokaiselle partikkeille annetaan alustuksessa sama paino $w_{1|0}^i = 1/N$. Algoritmi suoritetaan jokaiselle partikkeliille $i = 1, 2, \dots, N$ jokaisella ajanhettellä $k = 1, 2, \dots, t$. Algoritmin kuvaussa käytetään notaatiota x_k^i , joka tarkoittaa, että tila x_k käy ajanhettellä k gridin pisteessä x^i . Notaatiota tarvitaan, koska SMC-algoritmin läpikäymä gridi muuttuu ajan funktiona.

Seuraava toistetaan jokaiselle ajanhettkelle $k = 1, 2, \dots, t$. Algoritmin ensimmäisessä vaiheessa päivitetään painot yhtälön 12 mukaan.

$$w_{k|k}^i = \frac{1}{c_k} w_{k|k-1}^i p(y_k | x_k^i). \quad (12)$$

Tämä vastaa yllä esitetyn Bayes-suotimen päivitysvaihetta (6). Normalisointipaino c_k lasketaan puolestaan yhtälöstä (13), mikä vastaa Bayes-suotimen normalisointivakion laskemista (7) ja asettaa painojen summaksi $\sum_{i=1}^N w_{k|k}^i = 1$.

$$c_k = \sum_{i=1}^N w_{k|k-1}^i p(y_k | x_k^i). \quad (13)$$

Seuraavassa vaiheessa estimoidaan p laskemalla tiheyden $\hat{p}(x_{1:k} | y_{1:k})$ MC-estimaatti yhtälön (14) perusteella

$$\hat{p}(x_{1:k} | y_{1:k}) = \sum_{i=1}^N w_{k|k}^i \delta(x_{1:k} - x_{1:k}^i) \quad (14)$$

missä $\delta(x)$ on Diracinksi deltafunktio.

Seuraavassa vaiheessa suoritetaan valinnainen uudelleenotanta. Uudelleenotanta voidaan tehdä jojkaissella askelleella tai esimerkiksi efektiivisen otoskoon perusteella alla kuvatun kynnysarvoehdon $\hat{N}_{eff} < N_{th}$ täyttessä, jolloin uudelleenottantaa voidaan kutsua myös adaptiiviseksi uudelleenotannaksi. Tämä algoritmi on esitetty algoritmissa (2). Uudelleenottantaa tarkastellaan lähemmin alaluvussa 3.1.2. Lopuksi päivitetään aika (jos $k < t$) ja luodaan uudet ennusteet partikkeille ehdotusjakaumasta (15)

$$x_{k+1}^i \sim q(x_{k+1} | x_k^i, y_{k+1}) \quad (15)$$

ja päivitetään partikkelen painot tärkeytysotannalla (16), sen mukaan kuinka todennäköisiä partikkelen ennusteet ovat

$$w_{k+1|k}^i = w_{k|k}^i \frac{p(x_{k+1}^i | x_k^i)}{q(x_{k+1}^i | x_k^i, y_{k+1})}. \quad (16)$$

Vaiheet 15 ja 16 vastaavat Bayes-suotimen aikapäivitystä (8).

Alla käsitellään algoritmiin liittyvän uudelleenottamamenetelmän, partikkelen määrä / otoskoon ja ehdotusjakauman valinta. Lopuksi esitetään algoritmin konvergenssia, marginaalijakaumaa sekä aikakompleksisuutta koskevia tuloksia.

Algorithm 2: SIR-algoritmi

Result: Posteriorijakauman $p(x_{1:k}|y_{1:k})$ estimaatti.
Data: Havainnot y_k . Generoitu $x_1^i \sim p_{x_0}$ missä $i = 1, \dots, N$ ja jokainen partikkeli saa saman painon $w_{1|0}^i = 1/N$.

begin

```
for k = 1, 2, ..., t do
    for i = 1, 2, ..., N do
        begin
            | Päivitetään painot  $w_{k|k}$ .
        begin
            | Estimoidaan  $p$  laskemalla tiheydelle approksimaatio.

        begin
            | Lasketaan efektiivinen otoskoko  $\hat{N}_{eff}$ .
        if  $\hat{N}_{eff} < N_{th}$  then
            begin
                | Otetaan uudet  $N$  otosta palauttaen joukosta  $\{x_{1:k}^i\}_{i=1}^N$ , missä otoksen  $i$  todennäköisyys on
                |  $w_{k|k}^i$ .
            if  $k < t$  then
                begin
                    | Aikapäivitys.
                    | Luodaan ennusteet partikkeillel ehdotusjakaumasta  $x_{k+1}^i \sim q(x_{k+1}|x_k^i, y_{k+1})$ ,
                    | päivitetään partikkelen painot tärkeytysotannalla.
```

4.1 Parametrien valinta

Ennen algoritmin suorittamista valitaan ehdotusjakauma $q(x_{k+1}|x_{1:k}, y_{k+1})$, uudelleenotantamenetelmä sekä partikkelen määrä N . Ehdotusjakauman ja uudelleenotantamenetelmän valinnassa tärkeimpänä päämäääränä on välttää otosten ehtymistä, kun taas partikkelen määrä säätelee kompromissia algoritmin suorituskyvyn ja tarkkuuden välillä.

4.1.1 Otoskoon N valinta

Yleispätevää säädöötä otoskoon/partikkelen lukumääärän N valinnalle on vaikeaa antaa, sillä vaadittava estimointitarkkuus riippuu usein kässillä olevasta ongelmasta. Gordon &al. (1993) esittävät kuitenkin kolme tekijää, jotka vaikuttavat partikkelen lukumääärän valintaan

- tila-avaruuden ulottuvuuksien lukumääärä n_x ,
- tyypillinen päälekäisyys priorin ja uskottavuuden välillä
- sekä tarvittava aika-askeleiden lukumääärä.

Ensimmäisen tekijän vaikutus on selvä. Mitä useammassa ulottuvuudessa otantaa tarvitsee tehdä, sen korkeammaksi on N asetettava, jotta jokainen ulottuvuuus pystytään kattamaan. Tekijät (b) ja (c) puolestaan seuraavat uudelleenotannasta. Jos se osa tila-avaruutta, jossa uskottavuus $p(y_k|x_k)$ saa merkittäviä arvoja on pieni verrattuna siihen osaan, jossa priorijakauma $p(x_k|y_{1:k-1})$ saa merkittäviä arvoja, suuri osa partikkeleista saa pieniä painoja eivätkä näin valikoidu uudelleenotantaan.

Yleisesti ottaen N kannattaa asettaa sellaiseksi, että se paitsi tuottaa riittävän tarkan estimaatin, on se käytettävissä olevan laskentatehon sekä vaadittavan laskentanopeuden kannalta järkevä. Tähän palataan tutkielman lopuksi empiirisessä paikannusesimerkissä.

4.1.2 Uudelleenotantamenetelmän valinta

Ilman uudelleenotantaa on todennäköistä, että algoritmi alkaa kärsiä otosten ehtymisestä, kuten käy SIS-algoritmia käytettäessä. Toisin sanoen kaikki painot alkavat keskityä vain muutamalle partikkelille. Uudelleenotanta tarjoaa osittaisen ratkaisun tähän ongelmaan, mutta hävittää samalla informaatiota ja siten lisää satunnaisotantaan liittyvää epävarmuutta. Yleisesti ottaen kannattaa uudelleenotanta aloittaa vasta siinä vaiheessa algoritmin suorittamista, kun siitä on otosten ehtymisen kannalta hyötyä, esimerkiksi efektiivisen otoskoon laskettua jonkin kynnyssarvon alapuolelle (adaptiivinen uudelleenotanta). Efektiivinen otoskoko saadaan laskettua variaatiokertoimesta c_ν kaavalla

$$N_{eff} = \frac{N}{1 + c_\nu^2(w_{k|k}^i)} = \frac{N}{1 + \frac{\text{Var}(w_{k|k}^i)}{(\mathbb{E}[w_{k|k}^i])^2}} = \frac{N}{1 + N^2\text{Var}(w_{k|k}^i)}. \quad (17)$$

Nämä laskettu efektiivinen otoskoko maksimoituu ($N_{eff} = N$), kun kaikille painoille pätee $w_{k|k}^i = 1/N$ ja minimoituu ($N_{eff} = 1$), kun $w_{k|k}^i = 1$ todennäköisyydellä $1/N$ ja $w_{k|k}^i = 0$ todennäköisyydellä $(N-1)/N$. Tästä saadaan effektiiviselle otoskolle laskennallinen approksimaatio

$$\hat{N}_{eff} = \frac{1}{\sum_i (w_{k|k}^i)^2}. \quad (18)$$

Sekä määritelmälle (17) että (18) pätee $1 \leq \hat{N}_{eff} \leq N$. Yläraja saavutetaan, kun jokaisen partikkelin paino on sama. Alarajalle puolestaan päädytään, kun kaikki paino päätyy yksittäiselle partikkelille. Tästä saadaan määritellyä algoritmille SIR-uudelleenotantaehto $\hat{N}_{eff} < N_{th}$. Gustafsson (2010) esittää uudelleenotannan kynnyssarvoksi esimerkiksi $\hat{N}_{th} = 2N/3$.

Uudelleenotanta ei muuta approksimoitavan jakauma p odotusarvoa, mutta se lisää jakauman Monte Carlo -varianssia. On kuitenkin olemassa esimerkiksi osittamiseen perustuvia uudelleenotantamenetelmiä, jotka pyrkivät minimoimaan tämän varianssin lisäykseen. Varianssin pienentäminen jätetään tämän tutkielman ulkopuolelle.

4.1.3 Ehdotusjakauman valinta

Yksinkertaisin valinta ehdotusjakaumalle on $q(x_{1:k}|y_{1:k})$ eli toisin sanoen jokaisella algoritmin suorituskerralla käydään läpi koko polku $1 : k$. Tämä ei kuitenkaan ole tarkoituksemukaista, erityisesti jos kyseessä on reaalialkainen sovellus. Kirjoitetaan tämä ehdotusjakauma nyt muodossa

$$q(x_{1:k}|y_{1:k}) = q(x_k|x_{1:k-1}, y_{1:k})q(x_{1:k-1}|y_{1:k}). \quad (19)$$

Jos yhtälöstä (19) poimitaan ehdotusjakaumaksi ainoastaan termi $q(x_k|x_{1:k-1}, y_{1:k})$ saadaan tämän avulla muodostettua hyvä approksimaatio arvoille x_k . Tämä on suodinongelman kannalta riittävä, koska olemme kiinnostuneita ainoastaan posteriorijakaumasta ajanhetkellä k (tasoitusongelmassa tarvitsisimme koko polun $x_{1:k}$). Alla tarkastellaan edelleen Gustafsonia (2010) seuraten kahta ehdotusjakauman valintatapaa, prioritantaa (prior sampling) sekä uskottavuusontantaa (likelihood sampling).

Ennen ehdotusjakauman tarkastelua määritellään mallille signaali-kohinasuhde uskottavuuden maksimin ja priorin maksimin välisenä suhteena

$$\text{SNR} \propto \frac{\max_{x_k} p(y_k|x_k)}{\max_{x_k} p(x_k|x_{k-1})}. \quad (20)$$

Yhdistetään lisäksi ehdotusjakaumia varten yhtälöt (12) ja (13), jolloin saadaan painojen päivitys muotoon (21).

$$w_{k|k}^i \propto w_{k-1|k-1}^i \frac{p(y_k|x_k^i)p(x_k|x^{k-1})}{q(x_k|x_{k-1}^i, y_k)} \quad (21)$$

Kun suhde (20) on matala, on priorotanta luonnollinen valinta. Tässä käytetään ehdotusjakauman tilavektorin ehdollista prioria eli

$$q(x_k|x_{1:k-1}, y_k) = p(x_k|x_{k-1}^i). \quad (22)$$

Yhtälön (22) perusteella saadaan edelleen priorotannan painoiksi (23)

$$w_{k|k}^i = w_{k-1|k-1}^i p(y_k|x_k^i) = w_{k-1|k-1}^i p(y_k|x_k^i). \quad (23)$$

Kun taas signaali-kohinasuhde on kohtalainen tai korkea, on parempi käyttää ehdotusjakaumana skaalattua uskottavuusfunktiota (25). Tarkastellaan ensin tekijöihin jakoa (ref{uskottavuusotanta-factorization}).

$$p(x_k|x_{k-1}^i, y_k) = p(y_k|x_k) \frac{p(x_k|x_{k-1}^i)}{p(y_k|x_{k-1}^i)} \quad (24)$$

Kun SNR on korkea ja uskottavuusfunktio on integroituva pätee $p(x_k|x_{1:k-1}, y_k) \propto p(y_k|x_k)$, jolloin voidaan asettaa (25)

$$q(x_k|x_{1:k-1}, y_k) \propto p(y_k|x_k). \quad (25)$$

Yhtälön (25) perusteella saadaan edelleen uskottavuusotannan painoiksi (26).

$$w_{k|k}^i = w_{k-1|k-1}^i p(x_k^i|x_{k-1}^i). \quad (26)$$

4.2 Konvergenssituloksia

Alla esitetään kaksi algoritmiin liittyvä konvergenssitulosta, se kuinka hyvin esitettyllä SMC-algoritilla arvioitu posterioriheys $\hat{p}(x_{1:k}|y_{1:k})$ approksimoi todellista tiheysfunktiota $p(x_{1:k}|y_{1:k})$ sekä mikä on approksimaation keskineliövirhe. Tulokset noudattavat Crisanin ja Doucet'n artikkeleita "Convergence of Sequential Monte Carlo Methods" (2000) ja "A Survey of Convergence Results on Particle Filtering Methods for Practitioners" (2002).

Konvergenssitulos 1: Kun $N \rightarrow \infty$ algoritmile pätee $\forall k$ tulos (27).

$$\hat{p}(x_{1:k}|y_{1:k}) \xrightarrow{a.s.} p(x_{1:k}|y_{1:k}). \quad (27)$$

Konvergenssitulos 2: Keskineliövirheelle pätee asymptoottinen konvergenssi (28).

$$\mathbb{E}(\hat{g}(x_k) - \mathbb{E}(g(x_k)))^2 \leq \frac{p_k \|g(x_k)\|}{N}. \quad (28)$$

Missä g on mikä hyvänsä piilossa olevan tila-avaruuden rajoitettu Borel-mitallinen funktio ($g \in \mathcal{B}(\mathbb{R}^{n_x})$), $\|g(\cdot)\|$ kyseisen funktion supremum-normi ja p_k jokin äärellinen vakio, jolle pätee ajanhetkestä k riippumatta $p_k = p < \infty$. Konvergenssituloksia ei tämän tutkielman puitteissa todisteta.

4.3 Marginaalijakauma

Edellä kuvattu algoritmi 1 tuottaa approksimaation koko prosessin posteriorijakaumalle $p(x_{1:k}|y_{1:k})$. Jos halutaan tietää ainoastaan posteriorijakauman $p(x_k|y_{1:k})$ estimaatti, voidaan käyttää ainoastaan viimeisestä tilasta x_k^i laskettua estimaattia

$$\hat{p}(x_k|y_{1:k}) = \sum_{i=1}^N w_{k|k}^i \delta(x_k - x_k^i). \quad (29)$$

Toinen vaihtoehto on käyttää laskennassa tärkeytyspainoa

$$w_{k+1|k}^i = \frac{\sum_{j=1}^N w_{k|k}^j p(x_{k+1}^i|x_k^j)}{q(x_{k+1}^i|x_k^i, y_{k+1})} \quad (30)$$

yllä esitetyn sijaan. Tällöin jokaisessa aikapäivitysaskeleessa lasketaan painot kaikkien mahdollisten tila-aika-avaruuspolkujen yli. Samoin kuin uudelleenotanta tämä pienentää painojen varianssia.

4.4 Aikakompleksisuus

Algoritmin perusmuodon aikakompleksisuus on $\mathcal{O}(N)$. Uudelleenotantamenetelmän tai ehdotusjakauman valinta ei suoraan vaikuta aikakompleksisuuteen. Sen sijaan marginalisointi edellä esitetyllä tärkeytyspainolla lisää algoritmin aikakompleksisuutta $\mathcal{O}(N) \rightarrow \mathcal{O}(N^2)$, koska jokaisen partikkelin kohdalla painot lasketaan jokaisen tila-aika-avaruuspolun yli. On selvää, että erityisesti isoilla otoskoon N arvoilla ei yllä esitetty marginalisointi enää ole mielekästä.

Tällaisia tilanteita varten SMC-algoritmista on olemassa $\mathcal{O}(N \log(N))$ -versioita, jotka perustuvat N:n kappaleen oppimiseen (N-body learning). Näiden algoritmien käsitteily jää tämän tutkielman ulkopuolelle, mutta katsauksen algoritmeista ovat esittäneet esimerkiksi Klaas & al. artikkelissa "Toward Practical N^2 Monte Carlo: the Marginal Particle Filter" (2012). Tutkielman kahdessa ulottuuvuudessa tapahtuvan paikannusesimerkin tapauksessa $\mathcal{O}(N^2)$ -aikakompleksisuus ei ole ongelma.

5 Paikannusesimerkki

Sisätilapaikannus *** on BLAHBLAHBLAH. Koska GPS ei toimi sisätiloissa, tarvitaan muita paikannusratkaisuja. Radiosignaaleihin perustuvat paikannusratkaisut ovat BLAHBLAH. Eräs mahdollinen XXX, jossa käytetään tulokulmaa paikantamaan. Walkbase käyttää sisätilapaikannusta erityisesti ruokakaupoissa sekä tavarataloissa asiakkaiden käyttäytymistä koskevan keräämisen. Tyypillinen .. XXX ostoskärryihin ja -koreihin XXX keräämään tärkeää paikannusdataa asiakkaiden XXX. Markkinoilla on XXX on Walkbase kehittänyt oman laitteistoratkaisunsa. SKENAARIOISSA TARVITAAN Tavoitteena on alle metrin paikannusvirhe.

Esimerkissä käytetään SMC-algoritmia Bluetooth-paikannussovelluksessa paikannustarkkuuden parantamiseen. Paikannukseen käytettävä data kerätään toimistoympäristössä liikkuvien BLE-lähettimien sekä kattoon sijoitettujen vastaanottimien avulla. Havainnot koostuvat vastaanottimien lähettimien signaalien perusteella laskemista, BLE5.1-standardin mukaisista signaalil tulokulmista eli AoA-havainnoista (angle of arrival). Paikannukseen käytetään triangulaatio-algoritmia. Lopuksi esimerkissä analysoidaan ja vertaillaan algoritmin eri versioiden suorituskykyä sekä suorituskyvyn että paikannustarkkuuden näkökulmasta.

5.1 Koeasetelma

Paikannusesimerkissä lähettimenä toimi 25 Bluetooth-paikannustagista koostuva Walkbase Foculator - testilaite (kuva 1), vastaanottimena toimistoympäristöön asennettut seitsemän Walkbase XR-2 -vastaanotinta (kuva 2). Jokainen vastaanotin sisältää kahdeksan antennia, joiden vastaanottamien lähetinsignaalien perusteella vastaanottimet laskevat signaalil tulokulman suhteessa vastaanottimeen. Tarkka tulokulmien laskemiseen

käytetty algoritmi on paikantimen antennit toimittaneen Silicon Laboratories, Inc. -yrityksen liikesalaisuus, mutta ***perusperiaate on.

AoA relies on a single-antenna transmit beacon with continuous tone extension appended to a Bluetooth packet transmission and a locator receiver device to measure the arrival angle of the signal using an array of antennas. Each antenna in the array sees phase differences due to different line of sight distances to the beacon device. The antennas in the array are switched during continuous tone extension, resulting in IQ samples with phase information for each antenna. This IQ-data is fed to an angle estimator algorithm. In this AoA use case, the receiving device tracks arrival angles for individual transmit beacon objects.

Esteettömässä ympäristössä XXX kulman virhe on hyvin pieni ja paikannusongelma voidaan ratkaista suoraan jollakin triangulaatio-algoritilla. Erääänä XXX ToTal-algoritmia. Tässäkin tilanteessa voi paikannusta parantaa suodattimen käytöllä, mutta jo triangulaatioä-algoritmin perusversio tuottaa halutun tarkkuuden. Toimistoympäristö on kuitenkin haastava, sillä erityisesti näyttöruumut sekä heijastavat että estävät radiosignaaleja. Silicon Labs lupaa omalle AoA-järjestelmälle vastaavassa toimisympäristössä (seitsemällä paikantimella) kulmavirheen välillä $\pm 3.7 - 5.7$. Tämä ei kuitenkaan riitä johdonmukaisesti haluttuun alle metrin paikannustarkkuuteen, joten AoA-paikannus toimistoympäristössä tarjoaa hyvän motivaation SMC-menetelmien käyttämiseen.

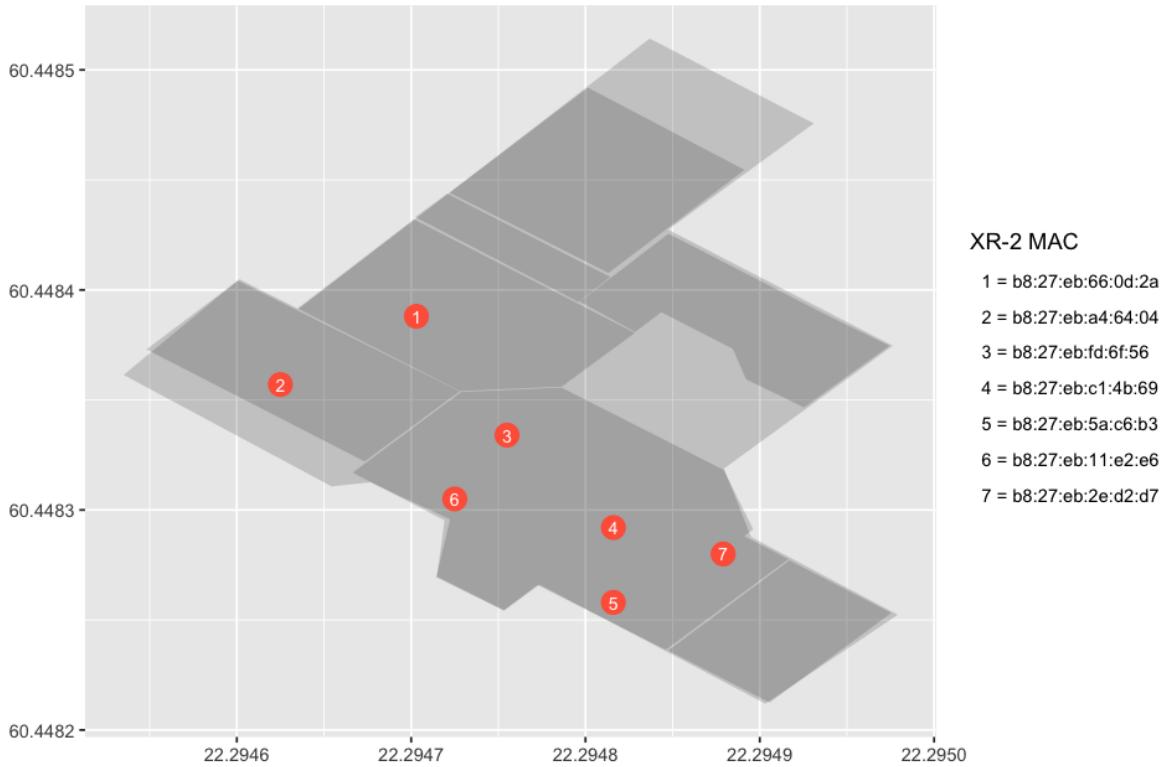


Kuva 1: Walkbase Foculator



Kuva 2: Walkbase XR-2

Data on kuvattu tarkemmin alaluvussa 4.2. Koeympäristön pohjapiirustus on esitetty kuvassa (3). Piirustuksessa XR-2-paikantimet on kuvattu punaisilla ympyröillä. Foculator-testilaitteen liikerata on kuvattu sinisellä viivalla. Toimistoympäristön pohjapiirustus on kuvattu harmaalla niin, että piirustuksesta erottuvat toimiston välineinät.



Kuva 3: Koeasetelman pohjapiirustus

Ennen datan keräämistä testilaite asennettiin kiinni robottiin (kuva 4) 1.5 metrin korkeudelle. Robotti oli ohjelmoitu ennalta seuraamaan haluttua liikerataa vastaavia lattiamerkintöjä ennalta määritetyllä nopeudella Xm/s . Kyseinen liikerata on merkitty koeympäristön pohjapiirustukseen sinisellä katkoviivalla. Data kerättiin sinä aikana, kun robotti liikkui liikeradan lähtöpisteestä (piste A) liikeradan maalipisteeseen (piste B). Robotilta kului matkaan Y sekuntia. Sekä korkeus että nopeus valittiin niin, että ne ovat XXX TÄ- GILLÄ MERKITYN ostoskärryjen liikkumista kauppaympäristössä. HUOMIO: Testaaminen vaikeammassa ympäristössä.



Kuva 4: Testirobotti

Data kerättiin yöaikana, jolloin toimiston käyttöaste oli minimissa. Tällä minimoitiin radiosignaalien tielle osuvien ihmisten vaikutus signaaleihin.

5.2 Datan kuvaus

Riippuen päällä olevien paikannustagien lukumäärästä, tuottaa n. havainto sekunnissa. Havaintoja on $N_{obs} = X$ kappaletta, joka kattaa Y minuuttia. Havaintojen aikaleimat on tallennettu sekunnin tuhannesosan tarkkuudella. Jokainen havainto koostuu taulukossa 1 havaintuista muuttujista.

Muuttuja	Kuvaus	Esimerkkiarvo
ts	havainnon aikaleima	21:38:20.998+00
asset_tag_mac	lähettimen MAC-osoite	5c:02:72:67:f7:4c
locator_mac	vastaanottimen MAC-osoite	b8:27:eb:66:0d:2a
locator_lat	vastaanottimen sijainti (leveyspiiri)	60.448265
locator_lon	vastaanottimen sijainti (pituuspiirit)	22.294823
bearing	suuntimakulma η (astetta)	34
height	vastaanottimen korkeus (m)	2.22
rssi	signaalin vahvuus (dBm)	-81
distance	arvioitu etäisyys lähettimeen (m)	13.5
azimuth_angle	atsimiuuttikulma ϕ (astetta)	102.7
converted_angle	napapohjoisesta laskettu kulma Φ (astetta)	34
opposite_angle	vastakkainen kulma (lähetin-vastaanotin) Φ' (radiaania)	3.735
elevation_angle	korkeuskulma (astetta)	11.9
quality_ant_phase_jitter	antennikohtainen jitter	(0.15,0.15,0.15,0.15, 0.14,0.16,0.29,0.34)
ss_jitter	antennikohtaisten jitter-arvojen neliösumma	0.3349
quality_ant_snr	antennikohtainen signaali-kohinasuhde	(24.76,37.48,40.75,36.37 28.5,28.2,16.15,11.27)
snr_jitter	antennikohtaisten signaali-kohinasuhteiden neliösumma	6996.473

Taulukko 1: Havaintomuuttujat

Etäisyys on estimoitu signaalin vahvuudesta käyttäen valmistajan omaa, tuntematonta propagaatiomallia. Etäisyyttä tai signaalin vahvuutta ei käytetä paikantamiseen, joten tämän mallin käsitteily jäätetään tutkielman ulkopuolelle. Munoz (2009) luku 2 sisältää yleiskatsauksen myös propagaatiomalleihin.

Atsimiuuttikulma ϕ lasketaan aina vastaanottimen tietyltä sivulta, joten se vastaa napapohjoista ainoastaan siinä tapauksessa, että vastaanottimen kyseinen sivu on asetettu kohtisuoraan napapohjoiseen nähdyn. Käytännön syistä tämä ei ole aina mahdollista eikä edes haluttavaa. Sen vuoksi jokaiselle vastaanottimelle on tietokantaan tallennettu oma suuntimakulma η . Triangulaatiossa alla käytetään napapohjoisesta laskettuja kulmia Φ , jotka lasketaan jokaiselle havainnolle havainnon vastaanottimen suuntimakulman avulla

$$\Phi = (\phi + \eta + 360^\circ) \mod 360^\circ. \quad (31)$$

Suuntimakulma Φ kertoo kuitenkin vastaanottimen ja lähetimen välisen kulman. Koske olemme kiinnostuneet paikantamaan lähetintä, lasketaan yhtälöllä (32) suuntimakulman perusteella edelleen lähetimen ja vastaanottimen välinen kulma Φ' . Samalla asteissa oleva kulma muunnetaan radiaaneiksi paikannusta varten.

$$\Phi' = \frac{\pi}{180^\circ}(\Phi + 180^\circ \mod 360^\circ). \quad (32)$$

Lisäksi havainnot sisältävät antennikohtaiset jitter- ja SNR-arvot sekä näistä lasketut neliösummat. Havaintomuuttujien ohella koitelanteessa tallennettiin Foculator-testilaitteen todellinen sijainti sekunnin tarkkuudella. Tallennettu sijainti perustui koeympäristön lattiaan pohjapiirrustusten ja laser-mittausten avulla tehtyihin merkintöihin. Näin saadut testimuuttujat on kuvattu taulukossa (2).

Muuttuja	Kuvaus	Esimerkkiarvo
foculator_ts	aikaleima	21:38:20+00
foculator_lat	testilaitteen sijainti (leveyspiiri)	60.44819
foculator_lon	testilaitteen sijainti (pituuspiiri)	22.29493

Taulukko 2: Testimuuttujat

Testimuuttuja käytetään alla SMC-paikannusalgoritmin paikannusvirheen laskemisessa.

5.3 Ongelman kuvaus

Tarkoituksesta on estimoida testilaitteen/robotin sijainti sekunnin tarkkuudella. Merkitään estimoitavaa tilasarjaa $x_{1:k} = \{x_1, \dots, x_k\}$. Lisäksi merkitään x_o testilaitteen lähtösijaintia. Jokainen tilasarjan havainto koostuu sekä pituus- että leveyskoordinaateista. Määritellään tilalle robotin kulkua kuvaava Markov-malli (33):

$$x_{k+1} = f(x_k, \nu_k) = x_k + D_k \begin{bmatrix} \cos \psi_k \\ \sin \psi_k \end{bmatrix} + \nu_k \quad (33)$$

missä D_k on testilaitteen/robotin ajanhetkenä k kuljema matka ja ψ_k robotin atsimuutti/suuntimakulma kyseisenä ajanhetkenä. ν_k on kohinaa, NORMAALIOLETUS. Vastaavasti $y_{1:k} = \{y_1, \dots, y_k\}$ kuvailee paikantimiensä ja lähettimien välillä laskettuja MUUTTUJAT.

$$y_k = h(x_k) + e_k = \text{MULTIANGULAATIONMALLI} \quad (34)$$

MALLIN VALINTA.

5.4 Algoritmi

Koeasetelmassa käytetty SMC-algoritmi on toteuttu koetta varten alusta asti R-kielellä. Daten käsitteelyyn koodi käyttää R:n tidyverse-kirjastoa. MUUT KÄYTETYT KIRJASTOT. Algoritmin koodi löytyy tutkielman liitteestä 1.

Algoritmin toteutuksessa on otettu huomioon seuraavat suorituskykyyn liittyvät pullonkaulat.

5.5 Tulokset

Koe toistettiin 6 kertaa. Ensimmäisessä vaiheessa testilaite pidettiin paikallaan ja kerättyyn dataan sovellettiin kolmea eri algoritmia. Ensin paikannus suoritettiin pelkän ToTal-algoritmin avulla. Tätä puhtaaseen triangulaatioon perustuvalta paikannusta käytetään vertailuarvona

SIR-algoritmin kohdalla partikkelen lukumääräksi valittiin $N = 1000$. SIR-algoritmin kohdalla käytettiin NEFF.

Vertailuarvoina käytettiin puhtaaseen triangulaatioon (TOTAL) perustuvaa XXX. Paikannusten keskipisteet on esitetty taulukossa (3). Parhaimman suorituskyvyn PAIKANNUSMIELESSÄ algoritmi valittiin lisätarkasteluun SMC-algoritmien parametrinvalintaan KOSKIEN.

Lisäksi algoritmin aikakompleksisuuteen vaikuttavat seuraavat seikat. T. SUORITUSKYKY. BATCH VS ONLINE. Kun halutaan on-line-estimointia, siinä missä off-line-estimointiin.

Koeasetelma	Algoritmi	Keskimääriinen paikannusvirhe ϵ	Sijaintien lukumäärä k
Testilaite paikoillaan	ToTaL		
Testilaite paikoillaan	SIR		
Testilaite paikoillaan	SIR (N-eff)		
Liikkova testilaite	ToTaL		
Liikkova testilaite	SIR		
Liikkova testilaite	SIR (N-eff)		

Taulukko 3: Paikannusvirheet

6 Lopuksi

Tässä tutkielmanmassa on esitetty pääpiirteittäin SMC-menetelmien teoria Bayesilaisessa/tilastotieteellisessä viitekehyksessä. Lisäksi tutkielmanmassa on käyty läpi uudelleenotantaa adaptiivisesti efektiivisen otoskoon perusteella hyödyntävä SIR-suodinalgoritmi. Tutkielmanmassa on myös käyty lävitse joitain algoritmien parametrien valintaan, suorituskykyyn sekä konvergenssiin liittyviä tuloksia.

Tutkielmanmassa on lisäksi tarkasteltu miten eri valinnat vaikuttavat algoritmin suorituskykyyn yksinkertaisen mutta kattavan ja todelliseen ongelmaan sekä dataan perustuvan paikannusesimerkin avulla. Jatkossa tutkielmaa olisi mahdollista laajentaa esimerkiksi JATKOKYSYMYKSIÄ.

7 Lähteet

- Chen & Liu (1998): **Sequential Monte Carlo Methods for Dynamic Systems.** http://stat.rutgers.edu/home/rongchen/publications/98JASA_SMC.pdf
- Crisan (2014): **The stochastic filtering problem: a brief historical account.** <https://www.cambridge.org/core/journals/journal-of-applied-probability/article/stochastic-filtering-problem-a-brief-historical-account/6B432F073F19A5488301BB49D0A0BA17>
- Crisan & Doucet (2000): **Convergence of Sequential Monte Carlo Methods.** http://www.stats.ox.ac.uk/~doucet/crisain_doucet_convergenceofSMC2000.pdf
- Crisan & Doucet (2002): **A Survey of Convergence Results on Particle Filtering Methods for Practitioners.** https://www.researchgate.net/publication/3318241_A_Survey_of_Convergence_Results_on_Particle_Filtering_Methods_for_Practitioners.
- Dahlin & Schön (2019): **Getting Started with Particle Metropolis-Hastings for Inference in Nonlinear Dynamical Models.** <https://arxiv.org/pdf/1511.01707.pdf>.
- Davidson, Collin & Takala (2010): **Application of Particle Filters for Indoor Positioning Using Floor Plans.** http://www.tkt.cs.tut.fi/research/nappo_files/Davidson_UPINLBS2010.pdf.
- Munoz, Bouchereau Lara, Vargas & Enriquez-Caldera (2009): **Position Location Techniques and Applications.** Elsevier.
- Del Moral (1996): **Nonlinear Filtering: Interacting Particle Resolution.** <https://people.bordeaux.inria.fr/pierre.delmoral/delmoral96nonlinear.pdf>.
- Gordon, Salmond & Smith (1993): **Novel approach to nonlinear/non-Gaussian Bayesian state estimation.** <http://www.irisa.fr/aspi/legland/ref/gordon93a.pdf>.
- Grewal & Andrews (2010): **Applications of Kalman Filtering in Aerospace 1960 to the Present.** <https://ieeexplore.ieee.org/document/5466132>.
- Gustafsson (2010): **Particle Filter Theory and Practice with Positioning Applications.** <https://ieeexplore.ieee.org/document/5546308>.
- Klaas, De Freitas, Doucet (2012): **Toward Practical N2 Monte Carlo: the Marginal Particle Filter.** <https://arxiv.org/abs/1207.1396>

- Petris, Petrone & Campagnoli (2009): **Dynamic Linear Models with R**. Springer.
- Särkkä (2013): **Bayesian Filtering and Smoothing**. Cambridge University Press. https://users.aalto.fi/~ssarkka/pub/cup_book_online_20131111.pdf.

Liite 1: SMC-paikannusalgoritmin R-koodi